IP2 - KLASIFIKACIJA UZORAKA TKIVA

1. Opis zadatka

Cilj ovog rada je izgradnja modela za klasifikaciju uzoraka tkiva na osnovu velikog broja atributa koji predstavljaju genetske karakteristike. Klasifikacija predstavlja jedan od osnovnih zadataka mašinskog učenja, gde je cilj naučiti model koji može da predvidi klasu novih, do tada neviđenih uzoraka.

U ovom problemu ciljni atribut je kolona **Tissue**, koja sadrži dve moguće klase: **Lung** i **Other**. Zadatak modela je da na osnovu vrednosti velikog broja atributa odredi kojoj klasi pripada dati uzorak.

Pošto skup podataka sadrži veoma veliki broj atributa u odnosu na broj instanci, poseban fokus rada stavljen je na obradu podataka i redukciju dimenzionalnosti. U radu su primenjene različite metode transformacije i selekcije atributa, kao i više algoritama mašinskog učenja, kako bi se uporedila njihova uspešnost u rešavanju ovog problema.

---

2. Opis skupa podataka

Originalni skup podataka sadrži **1545 instanci** i **10935 atributa**. Svaka instanca predstavlja jedan uzorak tkiva, dok atributi predstavljaju različite genetske karakteristike ili mere ekspresije gena.

Zbog velikog broja atributa u odnosu na broj instanci, ovaj skup podataka predstavlja tipičan primer **visokodimenzionalnog problema** u analizi podataka. U takvim slučajevima postoji rizik od prenaučenosti (overfitting), zbog čega je često potrebno primeniti metode redukcije dimenzionalnosti.

Ciljni atribut **Tissue** predstavlja klasu kojoj pripada uzorak. Za potrebe algoritama mašinskog učenja, kategorijalne vrednosti su transformisane u numerički oblik:

- **Lung = 1**
- **Other = 0**

Pre daljih koraka provereno je da li skup podataka sadrži nedostajuće vrednosti korišćenjem funkcije `df.isnull()`. Analiza je pokazala da nedostajuće vrednosti ne postoje, što je omogućilo direktnu primenu metoda transformacije i modeliranja.

---

3. Analiza distribucije podataka

Pre izgradnje modela izvršena je analiza statističkih karakteristika atributa kako bi se bolje razumela njihova raspodela. Posebno su analizirane vrednosti **skewness** i **kurtosis**, koje opisuju asimetriju i oblik distribucije podataka.

Rezultati analize pokazali su da veliki broj atributa ima izraženu asimetriju i veoma izražene repove distribucije. Srednja vrednost **skewness** iznosi približno **4.12**, dok srednja vrednost **kurtosis** iznosi oko **53.91**. Ove vrednosti ukazuju na značajno odstupanje od normalne raspodele i prisustvo ekstremnih vrednosti u podacima.

```
count    10935.000000
mean         4.124343
std          4.631818
min         -0.003285
25%          1.633869
50%          2.580549
75%          4.669467
max         39.193637
dtype: float64
count    10935.000000
mean        53.910506
std        142.596004
min         -0.854586
25%          5.198537
50%         12.575328
75%         38.093884
max       1538.997507
dtype: float64
```

Kako bi se smanjila asimetrija distribucije i stabilizovala varijansa atributa, primenjena je **Yeo-Johnson transformacija**. Ova transformacija predstavlja generalizaciju Box-Cox transformacije i pogodna je za podatke koji mogu sadržati i negativne vrednosti.

Nakon primene transformacije izvršena je vizuelna analiza distribucije atributa pomoću histograma. Histogrami su pokazali da transformisani atributi imaju distribuciju koja je znatno bliža normalnoj, odnosno zvonastoj raspodeli.

Histogram pre transformacije:

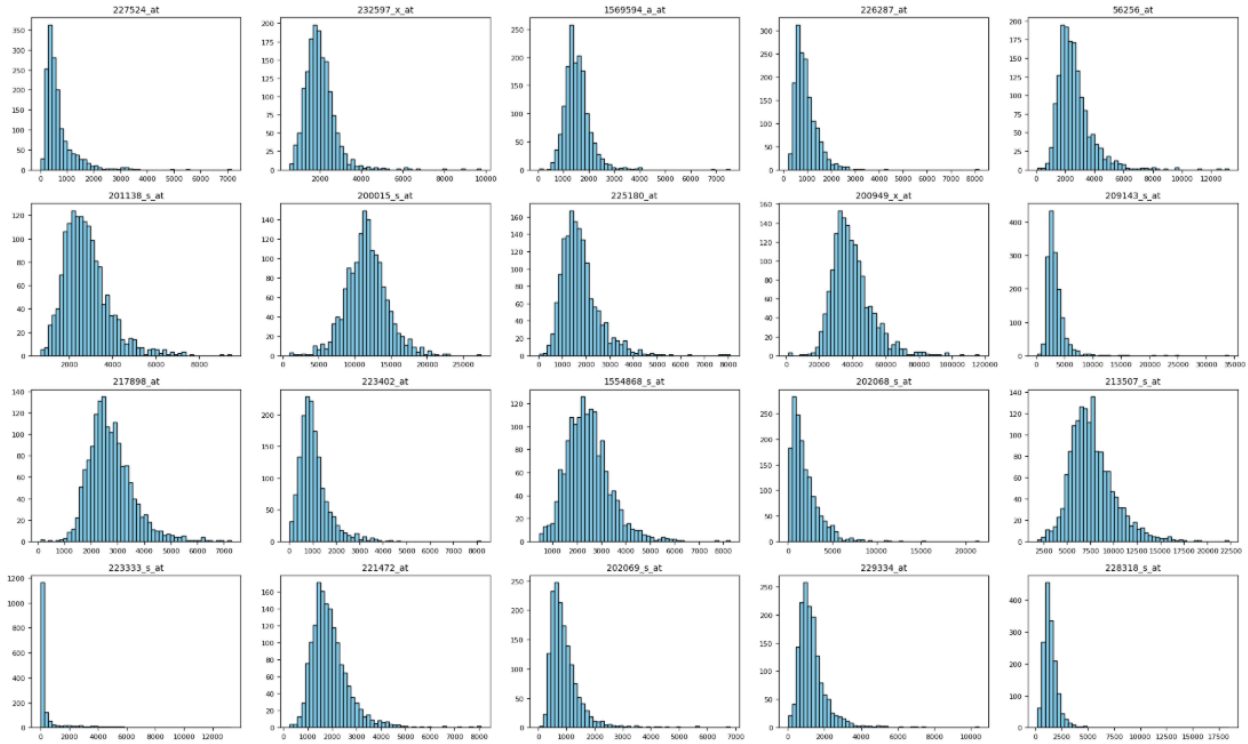

Histogram nakon transformacije:

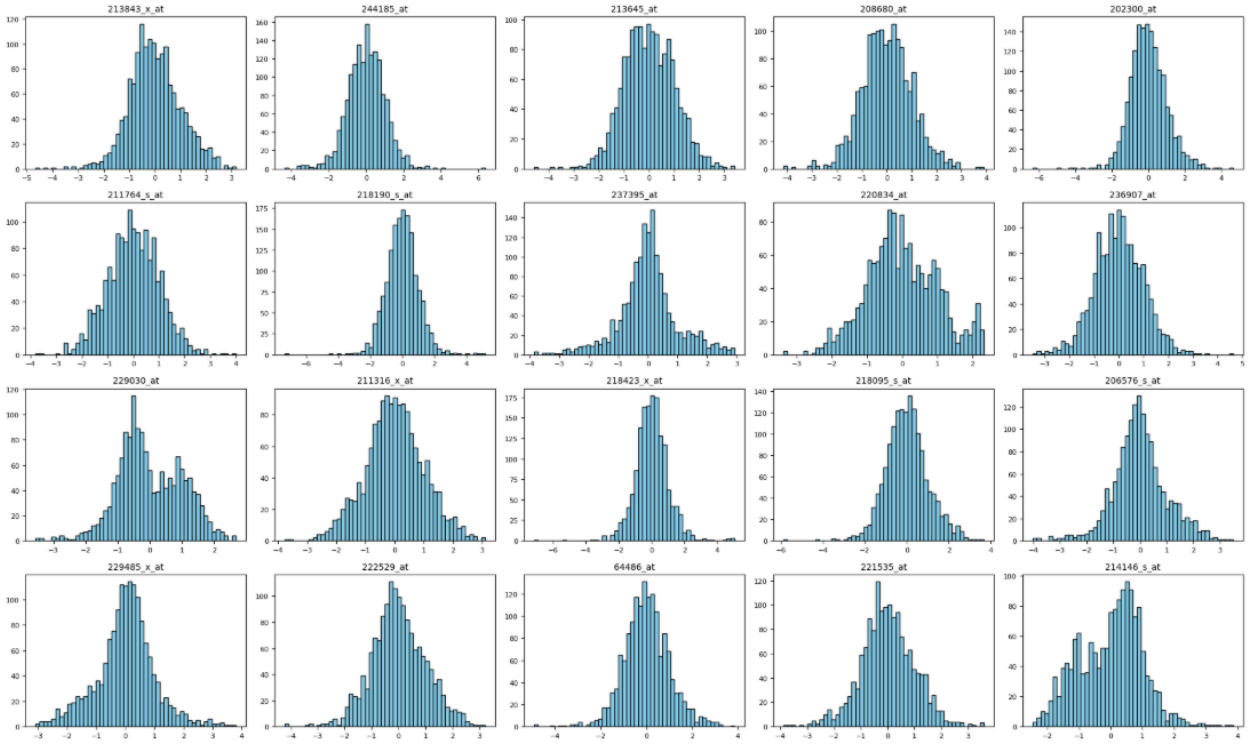

---

4. Standardizacija podataka

Nakon transformacije primenjena je standardizacija atributa pomoću metode **StandardScaler**. Ovaj postupak transformiše podatke tako da svaki atribut ima srednju vrednost jednaku nuli i standardnu devijaciju jednaku jedinici.

Standardizacija je posebno važna za algoritme mašinskog učenja koji zavise od skale atributa, kao što su **SVM**, **KNN** i **Logistic Regression**. Bez standardizacije atributi sa većim numeričkim opsegom mogli bi imati nesrazmerno veliki uticaj na rad modela.

---

5. Redukcija dimenzionalnosti

Zbog izuzetno velikog broja atributa primenjene su različite metode redukcije dimenzionalnosti. Cilj ovih metoda je smanjenje broja atributa uz očuvanje što više relevantnih informacija.

U radu su korišćene sledeće metode:

PCA (Principal Component Analysis)
PCA predstavlja tehniku koja transformiše originalne atribute u novi skup linearnih kombinacija atributa nazvanih glavne komponente. Ove komponente su međusobno ortogonalne i raspoređene tako da svaka naredna komponenta objašnjava sve manji deo ukupne varijanse podataka. U ovom radu zadržane su komponente koje zajedno objašnjavaju **95% ukupne varijanse**.

SelectKBest
Ova metoda vrši selekciju atributa na osnovu njihove statističke značajnosti u odnosu na ciljni atribut. U radu je korišćen **ANOVA F-test**, koji meri koliko se vrednosti atributa razlikuju između klasa. Izabrano je **800 atributa** sa najvećim F-vrednostima.

VarianceThreshold
Ova metoda uklanja atribute koji imaju veoma malu varijansu, odnosno atribute čije se vrednosti veoma malo razlikuju između instanci. Takvi atributi obično nose veoma malo korisnih informacija za klasifikaciju.

Broj atributa nakon redukcije dimenzionalnosti iznosi:

- Originalni skup: **10935 atributa**
- PCA: **733 atributa**
- SelectKBest: **800 atributa**
- VarianceThreshold: **1988 atributa**

---

6. Korišćeni algoritmi

U radu je korišćeno pet različitih algoritama klasifikacije:

- **Logistic Regression**
- **Linear SVM**
- **Random Forest**
- **KNN (k-najbližih suseda)**
- **Gradient Boosting**

Izbor algoritama izvršen je tako da obuhvati različite pristupe mašinskom učenju. Na taj način moguće je analizirati kako se različiti tipovi modela ponašaju na visokodimenzionalnim podacima i kako redukcija dimenzionalnosti utiče na njihove performanse.

Logistic Regression i Linear SVM predstavljaju **linearne modele** koji su često veoma efikasni u problemima sa velikim brojem atributa, naročito kada je broj instanci relativno mali u odnosu na dimenzionalnost skupa podataka. Ovi modeli su poznati po dobroj generalizaciji i često se koriste u problemima klasifikacije tekstualnih ili genetskih podataka.

KNN algoritam predstavlja **metodu zasnovanu na udaljenosti**, gde se klasifikacija vrši na osnovu sličnosti između instanci. Ovaj algoritam je posebno osetljiv na dimenzionalnost podataka, zbog čega je zanimljivo analizirati njegovu performansu nakon redukcije dimenzionalnosti.

Random Forest i Gradient Boosting predstavljaju **ansambl metode**, koje kombinuju više modela odlučivanja (decision trees) kako bi poboljšale tačnost i stabilnost klasifikacije. Random Forest koristi bagging pristup i nasumičnu selekciju atributa, dok Gradient Boosting gradi modele sekvencijalno tako da svaki naredni model ispravlja greške prethodnog.

Korišćenjem različitih tipova algoritama (linearnih modela, metoda zasnovanih na udaljenosti i ansambl metoda) omogućeno je sveobuhvatnije poređenje performansi i bolja analiza uticaja redukcije dimenzionalnosti na uspešnost klasifikacije.

Za početnu procenu performansi modela korišćena je **5-fold stratifikovana cross-validation metoda**. Ova metoda deli skup podataka na pet delova, pri čemu se u svakom koraku jedan deo koristi za testiranje, dok se preostali delovi koriste za treniranje modela. Stratifikacija obezbeđuje da raspodela klasa bude približno ista u svakom delu skupa podataka.

---

7. Rezultati i diskusija o njima

Performanse modela procenjivane su pomoću ROC-AUC, F1 i Recall metrike. ROC-AUC meri sposobnost modela da razlikuje dve klase kroz različite pragove klasifikacije, dok Recall pokazuje koliko uspešno model identifikuje pozitivne instance (klasu *Lung*). F1 metrika predstavlja balans između preciznosti i odziva i omogućava realniju procenu kvaliteta klasifikacije.

Rezultati dobijeni nakon primene različitih metoda redukcije dimenzionalnosti prikazani su u nastavku.

Kod **PCA redukcije dimenzionalnosti** najbolji rezultati ostvareni su kod modela Logistic Regression i Linear SVM, koji postižu ROC-AUC vrednosti oko 0.97, kao i vrlo visoke vrednosti F1 i Recall metrike (0.939 i 0.920). KNN model pokazuje nešto slabije rezultate, dok Gradient

Boosting ostvaruje srednje performanse. Random Forest u kombinaciji sa PCA pokazuje značajno lošije rezultate u odnosu na ostale algoritme, posebno u pogledu F1 i Recall metrika

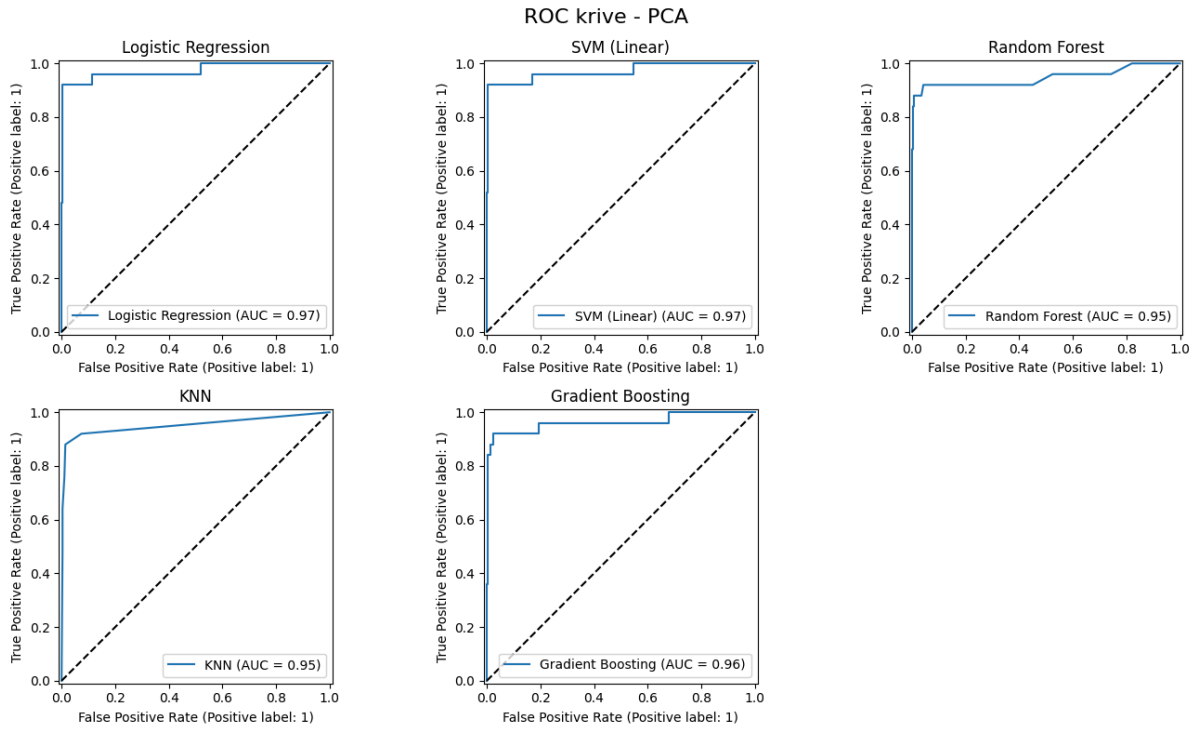

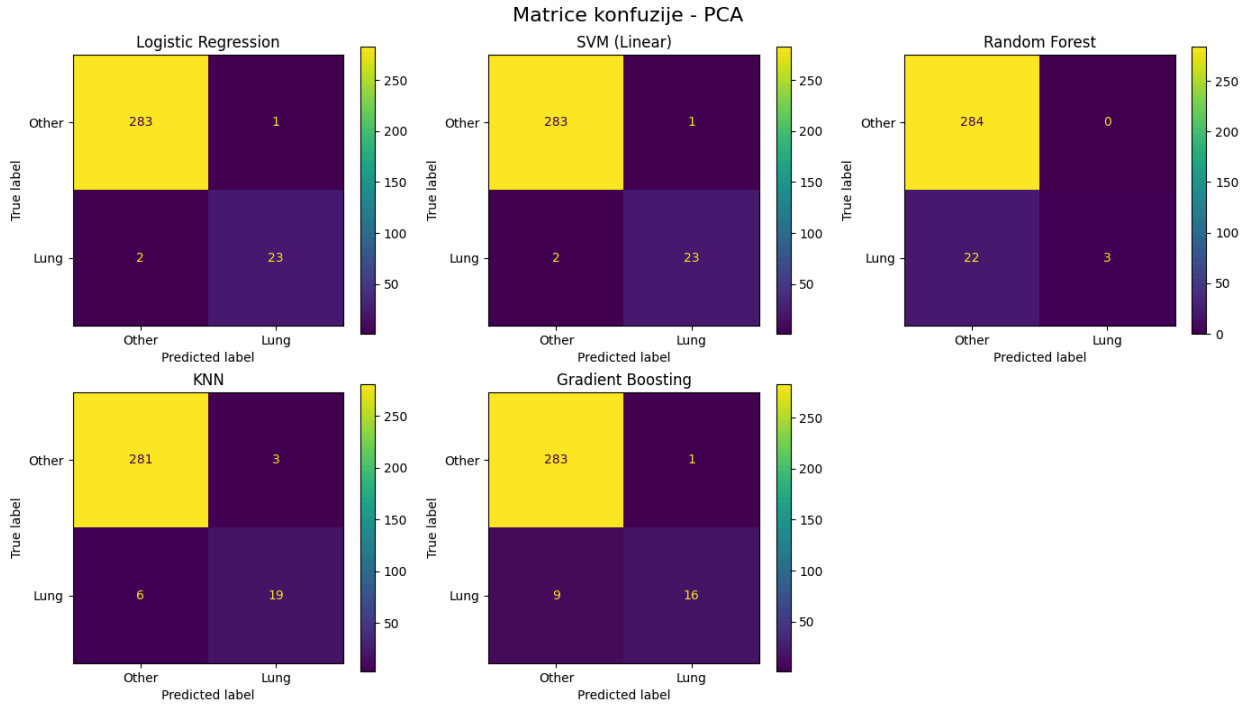

Kod **SelectKBest metode**, koja bira atribute na osnovu statističke značajnosti, rezultati su generalno stabilni za sve algoritme. Logistic Regression i SVM i dalje pokazuju dobre performanse, ali nešto niže nego kod PCA. Interesantno je da Random Forest i Gradient Boosting ostvaruju znatno bolje rezultate nego u PCA slučaju, što ukazuje na to da metode zasnovane na stablu mogu bolje da iskoriste originalne informativne atribute kada nisu transformisani u kombinovane komponente kao kod PCA.

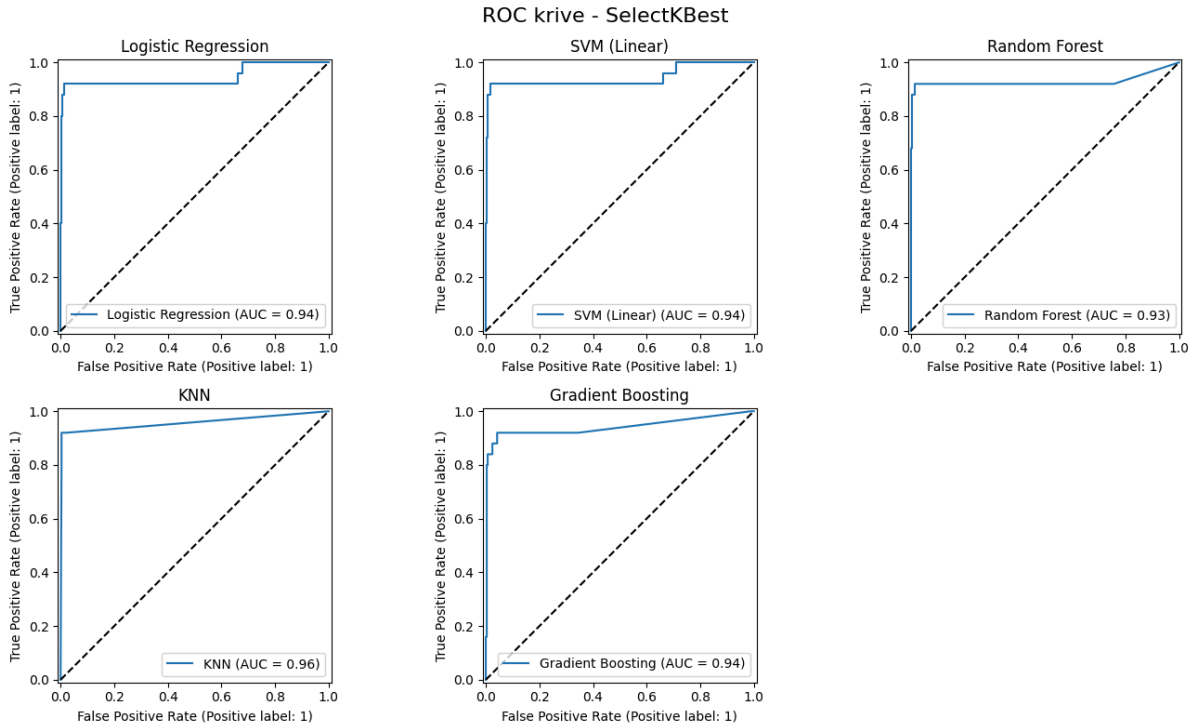

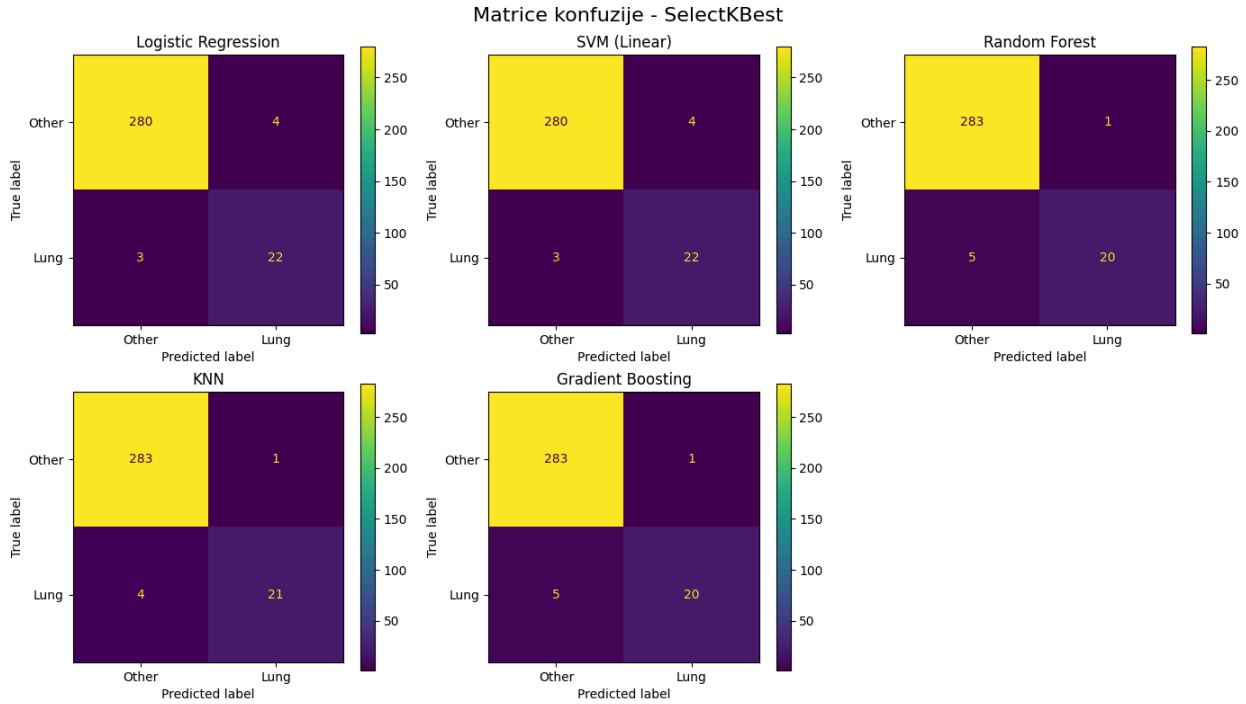

Kod **VarianceThreshold metode**, gde se uklanjaju atributi sa veoma malom varijancom, rezultati su ponovo vrlo dobri za linearne modele. Logistic Regression i SVM ostvaruju gotovo identične performanse kao kod PCA redukcije, dok Random Forest i Gradient Boosting postižu stabilne i relativno visoke vrednosti F1 i Recall metrike.

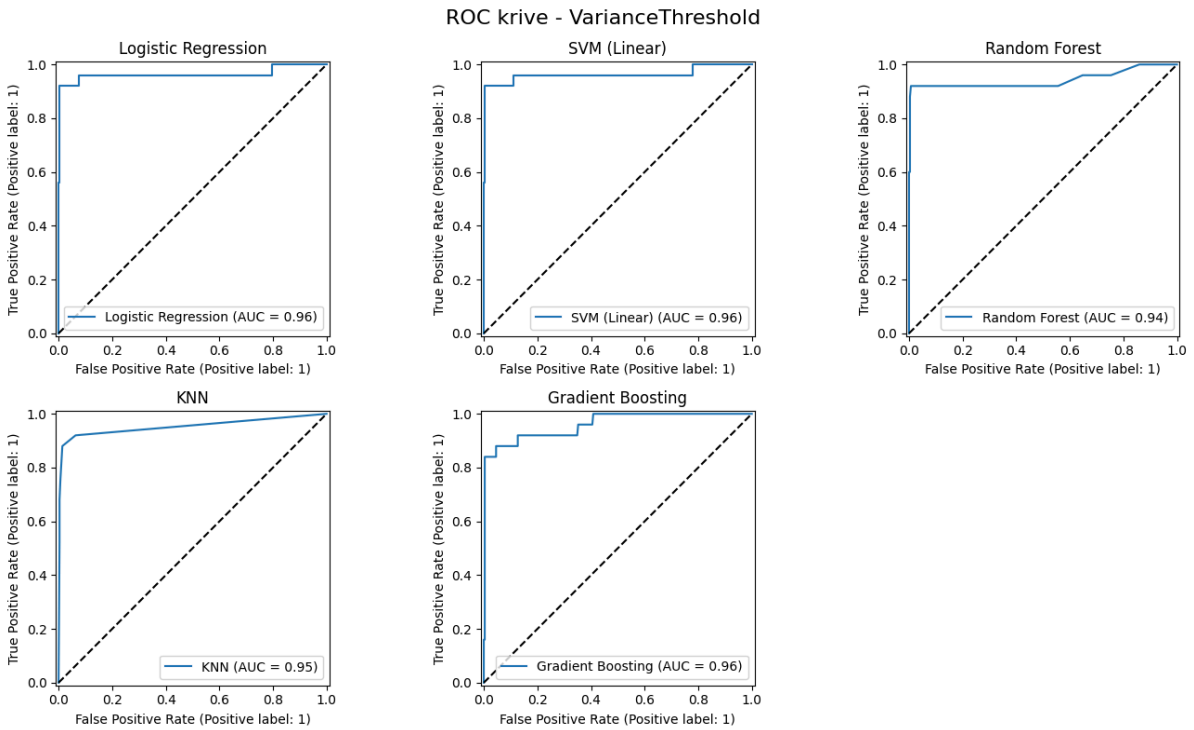

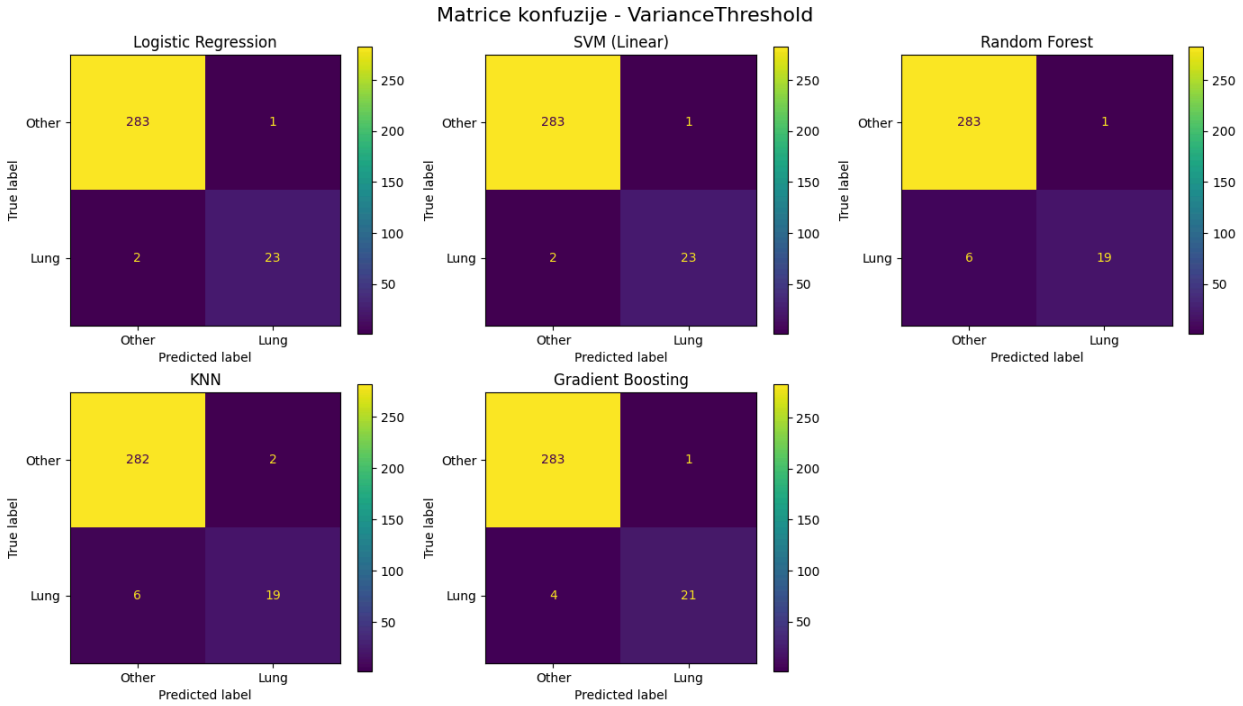

Dobijeni rezultati ukazuju na nekoliko važnih karakteristika ovog problema. Skup podataka ima veoma veliki broj atributa (10935) u odnosu na broj instanci (1545), što predstavlja tipičan primer problema visoke dimenzionalnosti koji je čest u bioinformatici i analizi genetskih podataka. U takvim situacijama linearni modeli često pokazuju veoma dobre performanse jer mogu efikasno da pronađu razdvajanje između klasa u prostoru velike dimenzionalnosti bez prevelikog rizika od preprilagođavanja modela.

Metode poput Random Forest i Gradient Boosting mogu imati poteškoće kada je broj atributa veoma veliki u odnosu na broj uzoraka, posebno kada se atributi transformišu metodama poput PCA koje kombinuju originalne informacije u nove komponente. To može objasniti znatno slabije performanse Random Forest modela u PCA scenariju.

Rezultati takođe pokazuju da redukcija dimenzionalnosti igra ključnu ulogu u performansama modela. PCA značajno smanjuje broj atributa uz očuvanje većine varijanse podataka, dok SelectKBest i VarianceThreshold uklanjaju manje informativne atribute. Sve tri metode doprinose stabilnijem i efikasnijem treniranju modela.

Na osnovu dobijenih rezultata može se zaključiti da su **Logistic Regression i Linear SVM** najpogodniji modeli za ovaj skup podataka, jer ostvaruju najviše vrednosti evaluacionih metrika i pokazuju stabilne performanse kroz različite metode redukcije dimenzionalnosti.

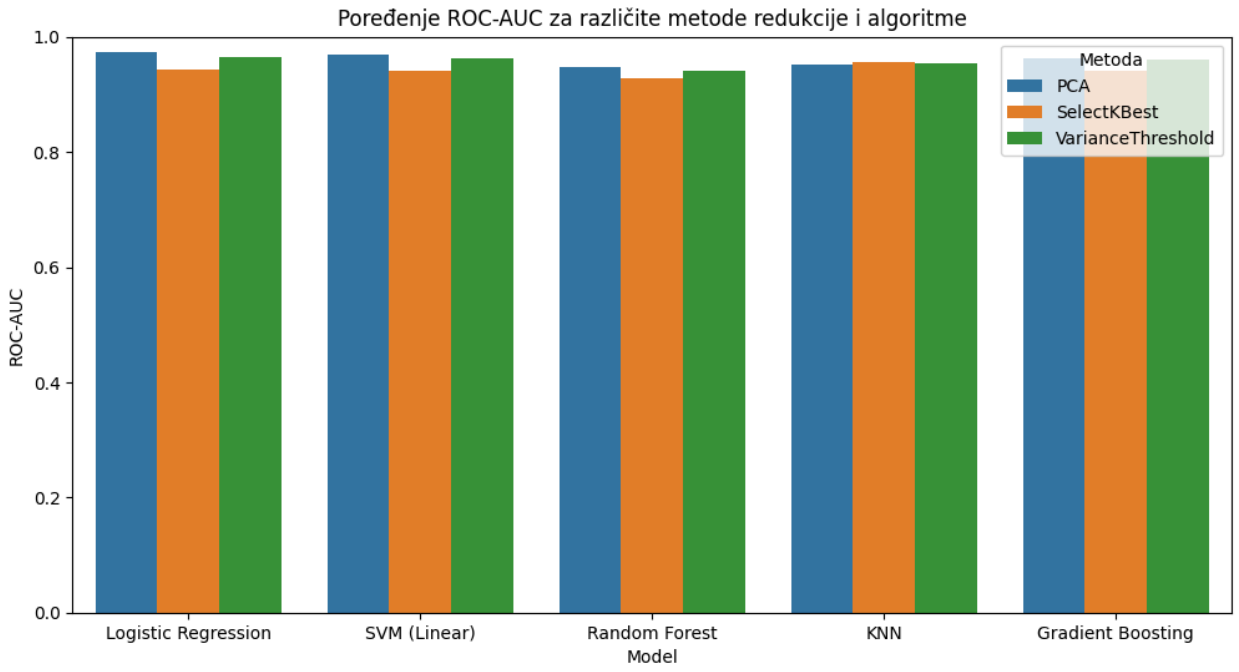

8. Literatura

- dokumentaciju za **sklearn PCA, Logistic Regression, SVM**
- medium.com **- Data science explained - log box-cox and yeo-jhohnson transform skewed data the right way**
- **https://www.kaggle.com/code/kkhandekar/top-10-algorithms-for-binary-classification**